

Visualització de dades

Part I: selecció del conjunt de dades

Índex

Índex	1
Elecció del dataset	2
Dades i context	2
Complexitat	3
Originalitat	4
Qüestions plantejades	5
Diccionari de variables	5
Preguntes plantejades	6


Elecció del dataset

En la primera part de la pràctica de l'assignatura de Visualització de dades hem de triar quin dataset estudiarem en la segona meitat. El dataset que he triat em sembla rellevant en l'àmbit personal: aquest estiu gairebé 400.000 hectàrees de terra s'han cremat a la península, fent que el 2025 sigui el pitjor dels últims trenta anys, superant per més de cent mil hectàrees el 2022 ([font](#), [font](#)). M'apassiona la muntanya i aquesta tragèdia ha canviat radicalment molts paisatges, i acabat amb la fauna i flora d'algunes de les regions més boniques.

[IberFire: a spatio-temporal dataset for wildfire risk assesment in Spain](#) és un dataset creat per membres d'[IK4-TEKNIKER](#) (una organització sense ànim de lucre del País Basc) i de la Universitat del País Basc i està creat per donar suport a estudis sobre el risc d'incendis forestals. És un dataset diferent dels que estic acostumada, però això em motiva: és un datacube en format [NetCDF](#) que, per cada dia entre desembre de 2007 i desembre de 2024, conté observacions diàries en una quadrícula de quilòmetres quadrats situats sobre la península. L'he obert i estudiat breument amb python, i en donaré detalls en els següents apartats.

Dades i context


Aquestes dades són rellevants actualment, ja que la quantitat d'hectàrees cremades ha augmentat de manera notable als últims anys, com he exposat en l'apartat anterior, com mostren diverses fonts de notícies amb gràfics comparatius:



Superfície cremada els últims 20 anys en incendis de 30 o més hectàrees ([font](#))

I no només a escala nacional, sinó que la quantitat d'arbres perduts mundialment també està creixent:

Global tree cover loss due to fires, 2001-2024



Non-fire related loss can occur from mechanical clearing for agriculture and logging, as well as natural causes such as wind damage and river meandering. The three-year moving average may represent a more accurate picture of the data trends due to uncertainty in year-to-year comparisons. All figures calculated with a 30 percent minimum tree cover canopy density.

Arbres perduts en focs els últims 25 anys ([font](#))

Per tant, els incendis forestals són un problema que té un impacte actual i real sobre tota la població mundial. En concret a Espanya, ha tingut un impacte immens sobre el sector primari, que ha quedat reflectit, fins i tot, al BOE: el [Ministeri d'agricultura, pesca i alimentació](#) ha proporcionat ajudes de gairebé trenta-mil milions d'euros per a agricultors, ramaders i asseguradors, amb un total de més de 10.000 beneficiaris.

Les dades trobades són prou actuals (arriben fins al desembre de l'any passat) i molt completes, amb 6.8×10^9 cel·les.

En aquest cas, les dades no són especialment rellevants des del punt de vista de la perspectiva de gènere, però també afecta un sector minoritari de la població: el sector primari representa només el 2.5% del PIB a Espanya, com mostra l'[Informe Anual d'Indicadors](#), i es troba en caiguda constant: als anys quaranta del segle passat més de la meitat de la població hi treballava ([font](#)).

Complexitat

Com he comentat, aquest dataset no es mesura necessàriament en columnes i files, ja que pren les dades en una quadrícula de mida 1km x km entre desembre de 2007 i desembre de 2024, en format [NetCDF](#). En concret, si obrim l'arxiu veiem que:

```
title: IberFire
description: Datacube centered in Spain with 1km x 1km spatial
resolution and daily temporal resolution.
```

```

dimensions: (y: 920, x: 1188, time: 6241)
spatial_resolution: 1km x 1km
temporal_resolution: Daily
start_date: 2007-12-01
end_date: 2024-12-31
crs: EPSG:3035
units_x: meters
units_y: meters
geospatial_x_min: 2674734.3466
geospatial_x_max: 3861734.3466
geospatial_y_min: 1573195.9911000002
geospatial_y_max: 2492195.9911
author: Julen Ercibengoa Calvo
author_contact:
    julen.ercibengoa@gmail.com,julen.ercibengoa@tekniker.es
creation_date: 2025-04-04
dimensions(sizes): y(920), x(1188), time(6241)
variables(dimensions): <valors recollits en cada posició>

```

Ho podem imaginar, per tant, com tres columnes més (x, y, time) que s'afegeixen en cada fila, a més de les columnes amb els valors hi ha a `variables`. Elaboraré un diccionari de variables en l'últim apartat, però en aquest apartat sí que vull mencionar que `variables` són 120 valors que contenen informació precisa de coordenades, sobre la natura del terreny (si és aquàtic, quin desnivell té) i les seves característiques (si és urbana, rural, industrial...). També té informació climàtica com ara temperatures i humitats, així com dades sobre la densitat de població, entre altres.

Per tant, la quantitat de dades satisfà el que demana l'enunciat i, a més, és prou complexa: inclou dades numèriques, categòriques (totes les etiquetes booleanes) i amb la informació geogràfica. A més, podem complementar la informació de comunitat autònoma proporcionada amb informació de Província, Comarca i Municipi, creant una jerarquia. També es pot complementar amb informació sobre la [quantitat de parcs de bombers per cada regió d'emergències](#), que són dades que ofereix la Generalitat per a Catalunya. Podem trobar informació equivalent per altres províncies i comunitats autònomes; ho detallaré en el següent apartat. També inclou dades geogràfiques i temporals, i el seu detall juntament amb l'estructura de DataCube, considero que proporciona prou complexitat per al problema proposat.

Originalitat

El dataset [d'IberFire](#) és nou (publicat enguany) i no està gaire treballat: llevat del [repositori amb el qual es va publicar](#) no he trobat cap estudi que el faci servir. És cert que el repositori mencionat és molt complet, però s'enfoca sobretot a la predicció d'incendis utilitzant models complexos, mentre que nosaltres voldrem respondre preguntes mitjançant visualitzacions; per tant, considero que són dos enfocaments prou diferents.

Per construir nova informació, faré servir les coordenades de cada quilòmetre quadrat de la graella per etiquetar-lo amb un municipi i província, així com la quantitat de població actual,

mitjançant el dataset [spain-municipalities-2024](#) que conté informació actualitzada el desembre de 2024, que coincideix amb la data de fi del dataset IberFire.

A més, centrant-nos en Catalunya, podem incorporar la [quantitat de parcs de bombers per cada regió d'emergències](#), i veure les seves posicions respecte als incendis i la densitat d'aquests, i així enriquir encara més el conjunt.

Com que les dades tenen dimensió temporal i geogràfica, moltes de les visualitzacions que es fan al repositori publicat involucren el mapa; tot i això, crec que hi ha molta informació que no és visualitzada i pot donar resultats interessants (estudiant els canvis en la densitat de població: són les zones on cau la densitat de població més properes a incendis? Hi ha alguna relació entre els moviments migratoris i els focs al bosc?).

Per tant crec que, si bé el conjunt de dades té un estudi prou complet al respecte, és només un i centrat en l'entrenament de models, cosa que ens deixa molt d'espai per explorar amb diferents visualitzacions. Juntament amb la combinació d'informació jeràrquica de Províncies i municipis, així com l'estudi detallat en combinació amb els parcs de bombers catalans, deixen molt d'espai per explorar, innovar i aportar resultats originals utilitzant el dataset.

Qüestions plantejades

En aquest apartat analitzaré quines qüestions vull respondre amb el conjunt de dades analitzat. Primerament, estudiaré les `variables` per entendre quina mena de dades tinc i com les puc utilitzar.

Diccionari de variables

- `x_index`, `y_index`: dimensió; valors enters dels intervals [0, 1187], [0,919] respectivament, que representen les coordenades x i y.
- `is_spain`: dimensió; booleà que representa si és Espanya o no.
- `is_fire`, `is_near_fire`: fet; booleans per indicar si hi ha foc dins la cel·la o es troba a prop de foc.
- `x_coordinate`, `y_coordinate`: dimensió; valors reals, corresponents a les coordenades EPSG:3035.
- `is_sea`, `is_waterbody`: dimensió; booleans que indiquen si el quilòmetre quadrat és aigua i/o mar.
- `AutonomousCommunities`: dimensió; enter [0,19] que indica la comunitat autònoma.
- `CLC_2006/2012/2018_<...>`: dimensió; proporcions entre 0 i 1 que indiquen el percentatge del quilòmetre quadrat que ocupa cada una de les explotacions dins de cada una de les tres etiquetes del projecte [CORINE Land Cover](#) als anys 2006, 2012 i 2018.
- `aspect_1...8,NODATA`: dimensió; proporcions entre 0 i 1 que indiquen la proporció del terreny que té cada inclinació.
- `elevation<...>`, `slope<...>`, `roughness<...>`: dimensió; valors relacionats amb el desnivell i inclinació del terreny.

- `dist_to<...>`: dimensió; mitjanes i desviacions de les distàncies a carreteres, rius i vies de tren en cada un dels quadrats de la graella.
- `is_natura2000`: dimensió; booleà que indica si forma part de la xarxa [Natura 2000](#).
- `popdens_20<...>`: dimensió; densitat depoblació en persones per quilòmetre quadrat per cada un dels anys entre 2008 i 2020.
- `is_holiday`: booleà que indica si és festiu o no.
- `t2m/RH/surface_pressure/total_precipitation/wind_speed/wind_direction_<...>`: dimensió; valors relatius al temps que ha fet en cada posició en cada dia concret: temperatura, humitat, pressió, precipitacions, direcció i velocitat del vent. Inclou mitjanes, rangs, mínims i màxims.
- `FAPAR`: dimensió; Fracció de Radiació Activa Absorvida Fotosintèticament
- `LAI, NDVI`: dimensió; índex de vegetació i fullatge per metre quadrat.
- `LST`: dimensió; Temperatura a la Superfície de la Terra, en graus Kelvin.
- `SWI_001/005/010/020`: dimensió; percentatge d'aigua al sol a 1, 5, 10 i 20 centímetres sota terra, respectivament.
- `FWI`: fet derivat; Fire Weather Index, columna afegida a la segona versió del dataset per ser utilitzada com a *baseline* model.

Preguntes plantejades

És important per a la visualització que preparem que existeixi una narrativa, així com que ofereixi un grau d'interactivitat. L'interactivitat s'aconseguirà permetent que l'usuari navegui pel temps, així com per la localització geogràfica, fent servir coordenades i municipis, províncies i comunitats autònomes.

La narrativa que seguida és la següent: en primer lloc veure on hi ha hagut incendis “a vista d'ocell” i després endinsar-se en les seves característiques:

1. **On i quan s'han produït incendis a Espanya entre 2007 i 2024?** Primerament veurem on s'han produït incendis al llarg del temps, utilitzant la variable `is_fire`.
2. **Quines condicions meteorològiques i de vegetació precedeixen un incendi?** Per respondre-la, entendrem quines característiques hi havia al terreny els cinc dies abans de l'incendi:
 - a. `LAI`
 - b. `NDV`
 - c. `LSDT`
 - d. `SWI_001/005/010/020`
 - e. `t2m/RH/surface_pressure/total_precipitation/wind_speed/wind_direction_<...>`.

Per entendre-ho millor, permetrem filtrar per tipus de terreny segons [CORINE Land Cover](#) i [Natura 2000](#). Així veurem si hi ha algun patró al sol que ens pot indicar risc d'incendi.

3. **Com influeix el tipus de terreny en l'inici i durada d'un incendi?** Tindrem en compte les característiques del terreny i la durada de l'incendi: així veurem si són

més fàcils de controlar en terrenys més inclinats, més baixos, etc. fent servir les variables `elevation<...>`, `slope<...>`, `roughness<...>` i `aspect`.

4. **Els incendis són més recurrents en zones poc poblades o poc comunicades?** Veurem els incendis en relació amb la densitat de població (`popdens_20<...>`), la comunicació del terreny (`dist_to<...>`) i n'estudiarem la freqüència. . Així veurem si la durada dels incendis té relació amb com d'urbanitzat està un terreny. Pel que fa a la densitat de població, com que només tenim 2 anys, farem mitjanes ponderades assumint un canvi lineal.
5. **A Catalunya, la proximitat a parcs de bombers influeix en la durada o extensió d'un incendi?** Veurem els detalls urbans: ens centrarem en Catalunya i la quantitat de parcs de bombers, relacionant-ne la quantitat amb la freqüència i durada dels incendis.

Finalment, sintetitzarem quins factors (ambientals, de terreny, d'ús del sòl o demogràfics) tenen més correlació amb la presència d'incendis i així extraurem les conclusions. Així, aconseguirem una visualització informativa que pot ser útil per al públic general i als gestors forestals, i que es podrà fer servir per guiar decisions preses en l'àmbit de previsió d'incendis.